

Επεξεργασία Σημάτων Φωνής και Ήχου

Εργασία

Γεώργιος Νικολαΐδης – ΑΜ. π21115

Εισαγωγή

Στα πλαίσια της παρούσας εργασίας αναπτύχθηκε ένα σύστημα δυαδικής ταξινόμησης φωνής (foreground) και θορύβου (background). Το σύστημα περιλαμβάνει τρία υποπρογράμματα: **εκπαίδευση** (train), **δοκιμή** (test), **αξιολόγηση** (evaluation). Η εκπαίδευση συμπεριλαμβάνει την κατασκευή ενός συνόλου δεδομένων με προκαθορισμένες ετικέτες αναφοράς που θα χρησιμοποιηθούν για να “μάθει” ο ταξινομητής να διακρίνει τους ήχους “foreground” από τους “background”. Έπειτα, γίνεται η εκπαίδευση του ταξινομητή χρησιμοποιώντας τα δεδομένα από το προηγούμενο βήμα. Στο στάδιο της δοκιμής, ένα ή περισσότερα αρχεία ήχου επεξεργάζονται, “περνάνε” από τον εκπαιδευμένο ταξινομητή, τίθενται επί μετα-επεξεργασία, και παράγεται ένα αρχείο CSV με τις χρονικές στιγμές που ο ήχος χαρακτηρίστηκε “foreground” και “background” από το σύστημα. Τέλος, η αξιολόγηση πραγματοποιείται με τη χρήση ενός CSV αρχείου από το στάδιο της δοκιμής, και ένα JSON αρχείο με transcriptions, το οποίο αποτελεί την πηγή αλήθειας. Διάφορες μετρικές υπολογίζονται και ύστερα συνδυάζονται για να παραχθεί ένα τελικό σκορ αξιολόγησης. Για περισσότερες πληροφορίες όσον αφορά την χρήση του συστήματος και των υποπρογραμμάτων του, δείτε το **Παράρτημα Α**.

Περιεχόμενα

Εισαγωγή.....	2
Προ-Επεξεργασία Δεδομένων.....	4
Εξαγωγή Χαρακτηριστικών.....	6
Θεωρητική Προσέγγιση.....	6
Επιλογή Χαρακτηριστικών.....	7
Χαρακτηριστικά Χρονικού Πεδίου.....	7
Χαρακτηριστικά Φασματικού Πεδίου.....	8
Ταξινόμηση.....	11
Μετα-Επεξεργασία.....	12
Κατασκευή Συνόλου Δεδομένων.....	13
Αξιολόγηση Επίδοσης.....	14
Αναφορά Επιδόσεων Ταξινομητών.....	15
MLP.....	15
k-NN.....	16
Παράρτημα Α – Εγχειρίδιο Χρήσης.....	17
Παράρτημα Β – Οπτικοποίηση Προβλέψεων.....	19
Αναφορές.....	21


Προ-Επεξεργασία Δεδομένων

Προτού ξεκινήσει η διαδικασία εξαγωγής χαρακτηριστικών, τα ηχητικά δεδομένα τίθενται υπό προ-επεξεργασία ώστε να έχουν μια πιο “κανονικοποιημένη” μορφή. Σκοπός είναι η αύξηση της ποιότητας των εξαγόμενων χαρακτηριστικών μέσω την εφαρμογή βασικών φίλτρων στο αρχικό σήμα ήχου. Επίσης, σε αυτό το στάδιο γίνεται η κατάτμηση του σήματος σε επικαλυπτόμενα πλαίσια.


Αρχικά, εφαρμόζεται **απομάκρυνση DC offset** που έχει ως αποτέλεσμα η μέση τιμή του σήματος ήχου να γίνει 0. Πρόκειται για κανονικοποίηση του σήματος που απαλείφει ανεπιθύμητες ιδιότητες του σήματος (παραμόρφωση, clipping)

Στη συνέχεια, χρησιμοποιείται ένα **φίλτρο προέμφασης**, το οποίο τονίζει κάποιες συχνότητες με βάση μια παράμετρο α . Η επιλογή της α ορίζει ποιες συχνότητες θα τονιστούν. Σε σήματα φωνής, έχει παρατηρηθεί και αποδειχθεί ότι η υψηλότερες συχνότητες που παράγονται με την ομιλία (πχ: το φώνημα “σ”) έχουν λιγότερη ένταση από τις χαμηλότερες (πχ: φωνήεντα). Με το φίλτρο προέμφασης μπορούμε να τονίσουμε τις υψηλότερες συχνότητες ώστε να έχουν την ίδια περίπου ένταση με τις χαμηλότερες. Για εφαρμογές επεξεργασίας φωνής η συνήθης επιλογή της παραμέτρου είναι $\alpha = 0.97$. Στο παρακάτω γράφημα απεικονίζονται δυο αναπαραστάσεις ενός σήματος ήχου στο χώρο των συχνοτήτων (Fourier Transform

και υπολογισμός log-magnitude). Το πάνω γράφημα δείχνει το φασματικό περιεχόμενο του σήματος χωρίς να έχει εφαρμοστεί το φίλτρο. Φαίνεται εύκολα η μείωση της έντασης όσο αυξάνονται η συχνότητες. Το κάτω γράφημα δείχνει το φασματικό περιεχόμενο του σήματος μετά από την εφαρμογή του φίλτρου και αναδεικνύεται η “ισορροπία” της έντασης σε όλο το πεδίο των συχνοτήτων.



Τέλος, το προ-επεξεργασμένο σήμα χωρίζεται σε μικρής διάρκειας επικαλυπτόμενα **πλαίσια** και κάθε ένα πολλαπλασιάζεται με μια συνάρτηση παραθύρου (Hamming, Hann, κ.α.) που απαλείφει την ασυνέχεια στην αρχή και το τέλος του σήματος, προκειμένου να μειωθεί η φασματική διαρροή. Η διαδικασία της κατάρτισης σε πλαίσια έχει δυο παραμέτρους: το μήκος του πλαισίου και το μήκος του hop (την απόσταση μεταξύ πλαισίων στο σήμα). Για να έχουμε επικαλυπτόμενα πλαίσια πρέπει το μήκος του hop να είναι μικρότερο του μήκους του πλαισίου. Συνήθως (και ως default στο κώδικα), το μήκος το πλαισίου είναι 25ms και το hop είναι 10ms. Από εδώ και πέρα, όλα τα μεταγενέστερα στάδια θα δουλεύουν με τα πλαίσια.



Εξαγωγή Χαρακτηριστικών

Σε αυτό το στάδιο το κάθε πλαίσιο μετατρέπεται από μια κυματομορφή σε ένα διάνυσμα χαρακτηριστικών (feature vector) που το περιγράφουν στο σύνολο του. Εδώ είναι **κρισιμότητα** η επιλογή των χαρακτηριστικών που θα αντιπροσωπεύουν τα πλαίσια. Αν τα επιλεγμένα χαρακτηριστικά δεν απεικονίζουν καθαρά τα πλαίσια που περιέχουν ομιλία και τα πλαίσια που έχουν θόρυβο, τότε ο ταξινομητής θα κάνει “μαντεψιές” αντί να διακρίνει μεταξύ foreground και background.

Θεωρητική Προσέγγιση

Προτού παρουσιαστούν και αναλυθούν τα χαρακτηριστικά που εξάγονται, αξίζει να σημειωθούν οι διαφορές μεταξύ ομιλίας και θορύβου, και τι ηχητικές ιδιότητες περιέχει η ομιλία ώστε να χρησιμοποιηθούν στην εξαγωγή χαρακτηριστικών.

Η ομιλία αποτελείται από δύο κύριες “υπό-κατηγορίες”: την φωνητική ομιλία και την άφωνη ομιλία[1]. Φωνήεντα και κάποια σύμφωνα (πχ: “β”, “ν”) εντάσσονται στην πρώτη, ενώ σύμφωνα όπως τα “σ” και “φ” ανήκουν στη δεύτερη. Η διάκριση γίνεται επειδή η πρώτη κατηγορία έχει ιδιαίτερο φασματικό περιεχόμενο που αποτελείται από την θεμελιώδη συχνότητα του ομιλητή και τις αρμονικές. Η δεύτερη κατηγορία δεν έχει αυτό το ιδιαίτερο φάσμα, και μοιάζει πολύ περισσότερο σε θόρυβο. Επειδή η ομιλία είναι συνδυασμός αυτών των δυο κατηγοριών, γίνεται πιο προκλητική η ανάλυση.

Στην άλλη μεριά, ο θόρυβος (πχ: βήματα, πιάτα που αντικρούονται) χαρακτηρίζεται από τα εξής:

1. Ομοιόμορφη κατανομή της φασματικής ενέργειας – η δομή του φάσματος είναι σχετικά επίπεδο, δηλαδή δεν υπάρχουν ευδιάκριτες κορυφές σε ορισμένες συχνότητες.
2. Μη-περιοδική κυματομορφή

Ορισμένες κατηγορίες θορύβου, όπως η μουσική ή ο στατικός θόρυβος που παράγει το μικρόφωνο μπορεί να μοιάζουν πιο πολύ σε ομιλία, αλλά και πάλι υπάρχουν διαφορές που επιτρέπουν την διάκριση μεταξύ τους.

Επιλογή Χαρακτηριστικών


Με το παραπάνω θεωρητικό υπόβαθρο, έγιναν οι παρακάτω επιλογές για τον χαρακτηρισμό του ήχου:

Χαρακτηριστικά Χρονικού Πεδίου

Παρόλο που τα περισσότερα χαρακτηριστικά εξάγονται από την φασματική αναπαράσταση του πλαισίου, υπάρχουν δύο χρήσιμες μετρικές στο πεδίο του χρόνου, η οποίες είναι αδιαχώριστο και συμπληρωματικό ζεύγος.

Αρχικά, ο **ρυθμός μηδενικών διελεύσεων (Zero-crossing rate - ZCR)** μετράει πόσες φορές μια κυματομορφή περνάει από τη τιμή 0. Η **ενέργεια μέσης τετραγωνικής ρίζας (root mean square energy - RMS)** είναι η τετραγωνική ρίζα της μέσης τετραγωνικής τιμής. Η ZCR συσχετίζεται με την συχνότητα – υψηλή ZCR υποδηλώνει την παρουσία και την κυριαρχία υψηλών συχνοτήτων, και αντιστρόφως. Η ενέργεια RMS δίνει την “ένταση” του σήματος και είναι υψηλή όταν δεν επικρατεί ησυχία. Η ενέργεια RMS από μόνη της δεν είναι ιδιαίτερα βοηθητική επειδή μολονότι η ομιλία έχει συνήθως υψηλή ενέργεια, ένα δυνατό κλείσιμο πόρτας μπορεί να έχει και υψηλότερη. Όμως, ως ζεύγος, αυτές οι δύο τιμές μπορούν να περιγράψουν σήματα ομιλίας έναντι σήματα θορύβου.

ZCR	RMS Energy	Ερμηνεία
Υψηλή	Υψηλή	Ορισμένες κατηγορίες θορύβου
Υψηλή	Χαμηλή	Άφωνα ομιλία (“σ”, “φ”, “θ”, κ.α.)
Χαμηλή	Υψηλή	Φωνητική ομιλία (φωνήεντα και κάποια σύμφωνα)
Χαμηλή	Χαμηλή	Σιγή



Χαρακτηριστικά Φασματικού Πεδίου

Στο πεδίο των συχνοτήτων γίνεται η περισσότερη δουλειά, χάρις στις ιδιαίτερες ιδιότητες της φωνής/ομιλίας σε αυτό. Το κύριο εργαλείο για όλα τα παρακάτω χαρακτηριστικά είναι ο μετασχηματισμός Fourier, που δίνει την αναπαράσταση μιας συνάρτησης στο πεδίο των συχνοτήτων. Η συνάρτηση που προκύπτει από τον μετασχηματισμό είναι μιγαδική και μπορεί να αναλυθεί με δύο τρόπους κυρίως: χρησιμοποιώντας το πραγματικό μέρος της συνάρτησης για να βρεθεί το μέτρο (magnitude) ή χρησιμοποιώντας το φανταστικό μέρος της συνάρτησης για να “αποκαλυφθεί” η φάση (phase). Επειδή ο μετασχηματισμός εφαρμόζεται ανά πλαίσιο διάρκειας ~25ms, η ανάλυση της φάσης δεν αποτελεί αντικείμενο ενδιαφέροντος διότι δεν υπάρχει ανάγκη για χρονική πληροφορία όσο γίνεται δουλειά στο φασματικό πεδίο.

Το πιο σημαντικά χαρακτηριστικά είναι οι συνιστώσες του **Mel-Frequency Cepstrum (Mel-Frequency Cepstrum Coefficients – MFCC)**. Οι συνιστώσες είναι σημαντικές επειδή περιγράφουν/προσεγγίζουν την φασματική περιβάλλουσα (spectral envelope). Αυτό είναι κρίσιμο διότι η φασματική περιβάλλουσα δείχνει ξεκάθαρα την θεμελιώδη συχνότητα και τις αρμονικές. Η διαδικασία για να υπολογιστούν οι συνιστώσες περιλαμβάνει πολλά βήματα, τα οποία περιγράφονται περιληπτικά παρακάτω. Η διαδικασία δέχεται ως είσοδο ένα πλαίσιο.

1. Υπολογισμός του φάσματος ισχύος (power spectrum), που προκύπτει από το τετράγωνο του μέτρου του μετασχηματισμού Fourier (square of FT magnitude).
2. Υπολογισμός της τράπεζας φίλτρων Mel (filterbank). Το αποτέλεσμα είναι ένας πίνακας (matrix) με ένα φίλτρο ανά γραμμή.
3. Πολλαπλασιασμός (matrix-vector multiplication) του Mel filterbank με το φάσμα ισχύος. Το αποτέλεσμα είναι η απαλοιφή της λεπτομέρειας και η έμφαση του ολικού σχήματος του φάσματος.
4. Υπολογισμός του λογαρίθμου του πολλαπλασιασμού για την συμπίεση του εύρους τιμών, που αρχικά είναι πολύ μεγάλο.
5. Υπολογισμός του διακριτού μετασχηματισμού συνημιτόνων (Discrete Cosine Transform – DCT). Η έξοδος του μετασχηματισμού δίνει τις συνιστώσες που περιγράφουν την ενέργεια του σήματος καθώς και τις θέσεις των φορμάντ (formant).

Επιπλέον, οι MFCCs χρησιμοποιούνται και στο υπολογισμό άλλων χαρακτηριστικών, που είναι στη ουσία συναρτήσεις των εν λόγω συνιστωσών. Αυτά τα χαρακτηριστικά είναι τα Δ (δέλτα – πρώτη παράγωγος) και τα $\Delta\Delta$ (δέλτα-δέλτα – δεύτερη παράγωγος), που δίνουν τον ρυθμό μεταβολής των MFCC. Έτσι, προστίθεται και χρονική πληροφορία στα χαρακτηριστικά, επειδή με το ρυθμό μεταβολής γίνεται δυνατός ο εντοπισμός του τέλους ενός φωνήματος, και ως αποτέλεσμα μπορούμε να διακρίνουμε τη διαφορά μεταξύ θορύβου και άφωνης ομιλίας.

Τέλος, υπολογίζεται η **φασματική εντροπία** (spectral entropy). (“Εντροπία” εδώ αναφέρεται στην εντροπία Shannon). Όπως είναι γνωστό, η εντροπία ποσοτικοποιεί την πληροφορία που περιέχει μια κατανομή ή ακολουθία από σύμβολα – υψηλή εντροπία σημαίνει υψηλή τυχαιότητα. Εδώ, η κατανομή/ακολουθία είναι οι συχνότητες και η ισχύς σε κάθε σημείο. Ο θόρυβος συχνά έχει πολύ υψηλή εντροπία

χάρης στο ομοιόμορφο φάσμα του, η φωνητική ομιλία έχει πολύ χαμηλή εντροπία διότι οι συχνότητες είναι συγκεντρωμένες σε μια μικρή περιοχή και το υπόλοιπο φάσμα έχει πολύ λίγη ισχύ, και η άφωνη ομιλία είναι κάπου ανάμεσα στα δύο. Είναι πολύ καλό συμπλήρωμα για τα MFCCs.

Τα χαρακτηριστικά που αναφέρθηκαν παραπάνω υπολογίζονται για κάθε πλαίσιο και προστίθενται σε ένα διάνυσμα που τελικά αποτελεί το διάνυσμα χαρακτηριστικών (feature vector) για το πλαίσιο. Τα χαρακτηριστικά ανά πλαίσιο ενός ολόκληρου σήματος ήχου μπορούν να αναπαρασταθούν με ένα πίνακα (matrix) που η γραμμή i αντιστοιχεί στο διάνυσμα χαρακτηριστικών του i -οστού πλαισίου.

$$\mathbf{X} = \begin{bmatrix} \text{—} & f_1 & \text{—} \\ \text{—} & f_2 & \text{—} \\ & \vdots & \\ \text{—} & f_n & \text{—} \end{bmatrix}$$

Ταξινόμηση

Στο στάδιο της ταξινόμησης, ο ταξινομητής (k-NN ή MLP) δέχεται είσοδο πίνακα χαρακτηριστικών X και παράγει έξοδο ένα διάνυσμα ετικετών y που κάθε στοιχείο του είναι 0 ή 1. Το 0 σημαίνει background ενώ το 1 foreground. Το i -οστό στοιχείο του y αντιστοιχεί στο i -οστό πλαίσιο.

Ο ταξινομητής δεν μπορεί να ταξινομήσει χαρακτηριστικά εάν δεν έχει πρώτα εκπαιδευτεί. Έτσι, προτού μπορέσει να κάνει τη δουλειά του, θα πρέπει πρώτα να μάθει. Για αυτό το σκοπό έχει και λειτουργικότητα εκπαίδευσης, που μαθαίνει να ταξινομεί χαρακτηριστικά (X_{train}) για τα οποία είναι δοσμένες οι ετικέτες (y_{train}). Όταν ολοκληρωθεί η εκπαίδευση, τα βάρη και οι παράμετροι που “έμαθε” ο ταξινομητής αποθηκεύονται για μελλοντική χρήση.

Μετα-Επεξεργασία

Ως τελικό στάδιο του pipeline, η μετα-επεξεργασία τροποποιεί το “ωμό” διάνυσμα ετικετών που παράγεται από το στάδιο της ταξινόμησης κάνοντας διάφορες πιθανές διορθώσεις και βελτιώσεις. Παράγει μια ακολουθία “τμημάτων” (segments) που κάθε τμήμα είναι foreground ή background και έχει μια χρονική διάρκεια (αρχή και τέλος).

Αρχικά, εφαρμόζεται ένα **φίλτρο διαμέσου** (median filter). Το φίλτρο είναι ουσιαστικά ένα βρόχος που προσπελάζει κάθε στοιχείο του διανύσματος ετικετών y . Σε κάθε επανάληψη, θεωρεί τα γειτονικά στοιχεία και υπολογίζει τη διάμεσο Md_i . Αν η διάμεσος είναι $Md_i \geq 0.5$, τότε η ετικέτα y_i παίρνει τη τιμή 1, αλλιώς 0. Το αποτέλεσμα αυτής της διαδικασίας είναι το “smoothing” του y , και αντικατοπτρίζει καλύτερα τη πραγματικότητα διότι στην ομιλία σχεδόν ποτέ δεν υπάρχει για παράδειγμα ένα κενό ~30ms – είναι πολύ σύντομο. Εννοείται όμως πως δεν είναι τέλειο: λ.χ. αν κάποια χρονική στιγμή επικρατεί μόνο θόρυβος και κάποιος εκφωνήσει ένα κοφτό και σύντομο “α”, τότε παρόλο που θα εντοπιστεί από το ταξινομητή, θα απαλειφθεί από το φίλτρο διαμέσου διότι τα πλαίσια γύρω από το “α” είναι μόνο θόρυβος.

Στη συνέχεια, επεκτείνεται η διάρκεια της ομιλίας στο διάνυσμα ετικετών με το **“hang-over” φίλτρο**. Η λειτουργία του είναι πολύ απλή, αν ένα πλαίσιο έχει ταξινομηθεί “ομιλία” (1), τότε θέσε τα επόμενα N πλαίσια ίσα με 1.

Το τελευταίο βήμα πρόκειται για την **απαλοιφή μικρής-διάρκειας τμημάτων foreground/background**. Αυτό, γίνεται για να εξαφανιστούν εντελώς οι απότομες αλλαγές, οι οποίες – μέσω εμπειρικής διαπίστωσης, μειώνουν την ποιότητα και την ακρίβεια των τμημάτων.

Κατασκευή Συνόλου Δεδομένων

Αυτό το στάδιο είναι κρίσιμο για την σωστή εκπαίδευση του ταξινομητή. Υπάρχουν πολλοί παράγοντες που πρέπει να ισορροπηθούν ώστε το σύνολο δεδομένων αντικατοπτρίζει σωστά τη πραγματικότητα και την αλήθεια. Οι παράγοντες είναι:

- Το μέγεθος του συνόλου. Περισσότερα δεδομένα δεν σημαίνει καλύτερη απόδοση και διατύπωση της αλήθειας. Πρέπει το σύνολο να έχει ένα μέγεθος αρκετά μεγάλο για να μπορέσει ο ταξινομητής να μάθει διάφορες ομιλίες (ανδρικές φωνές και γυναικείες φωνές, ομιλία με θόρυβο και χωρίς) και αρκετά μικρό ώστε να μην γίνει overfitting.
- Η αναλογία “αρνητικών” δεδομένων – σκέτο θορύβου, προς των “θετικών” δεδομένων – ομιλίας με ή χωρίς θόρυβο. Πρέπει να είναι ίση γιατί αν όχι, ο ταξινομητής θα είναι προκατειλημμένος και θα ταξινομεί πιο συχνά δεδομένα στη κατηγορία που υπερισχύει στην αναλογία.
- Ομιλία με παρουσία θορύβου. Το σύνολο αρχείων εκπαίδευσης που δόθηκε, αποτελείται από ομιλία σε περιβάλλον χωρίς θορύβους στο υπόβαθρο. Αυτό το γεγονός είναι εξαιρετικό διότι μπορεί να μάθει ο ταξινομητής ακριβώς πως ακούγεται μια φωνή από μόνη της, αλλά δεν είναι όλη η αλήθεια. Στη πραγματικότητα (και στα αρχείο δοκιμής της εργασίας), η ομιλία “μπλέκεται” με διάφορους θορύβους υποβάθρου.

Η κατασκευή του συνόλου δεδομένων ξεκινάει με την εισαγωγή όλων των αρχείων ομιλίας (speech) και θορύβου (noise). Ύστερα, ο σκέτος θόρυβος θεωρείται “background” αρά του ανατίθεται η ετικέτα 0. Η σκέτη ομιλία θεωρείται “foreground”, επομένως της ανατίθεται η ετικέτα 1. Επιπλέον, γίνεται ανάμειξη ομιλίας/θορύβου σε διαφορετικά επίπεδα SNR (Signal-to-Noise ratio) από 0dB (ο θόρυβος υπερισχύει) έως ~20dB (η ομιλία υπερισχύει σχεδόν εντελώς) και σε αυτά επίσης δίνεται η ετικέτα 1. Τέλος, επειδή οι δύο κλάσεις (foreground/background) μπορεί να είναι δυσανάλογες, γίνονται πιθανές περικοπές στο σύνολο δεδομένων για να υπάρξει 50/50 ισορροπία δεδομένων foreground και background. Η έξοδος που παράγει αυτό το στάδιο είναι ο πίνακας χαρακτηριστικών εκπαίδευσης X_{train} και το διάνυσμα ετικετών εκπαίδευσης y_{train} .

Αξιολόγηση Επίδοσης

Αναπτύχθηκαν διάφορες μετρικές επίδοσης, η οποίες συνδυάζονται και παράγουν ένα κανονικοποιημένο ολικό σκορ από 0 έως 1. Όλες οι μετρικές υπολογίζονται από δύο ακολουθίες τμημάτων (segments): την ακολουθία των προβλέψεων (predictions) και την ακολουθία του ground-truth, η οποία παράγεται από ένα JSON transcript (όπως αυτό που δόθηκε). Οι μετρικές είναι οι εξής:

- **Recall[2]** – πόση από την ground-truth ομιλία προβλέφθηκε.
- **Miss Rate** – πόση από την ground-truth ομιλία δεν προβλέφθηκε, είναι ο αντίστροφος του Recall ($1 - \text{Recall}$)
- **Precision[2]** – από το συνολικό χρόνο που το σύστημα προέβλεψε “foreground”, πόσος ήταν όντως ομιλία;
- **F1[3]** – το αρμονικό μέσο των recall και precision.
- **False-Alarm Rate (FAR)** – ποσοστό που το σύστημα προέβλεψε “foreground” ενώ στη πραγματικότητα ήταν “background”
- **Segmentation Ratio** – η αναλογία του αριθμού των “foreground” τμημάτων στην πρόβλεψη προς τον αριθμό των “foreground” τμημάτων στο ground-truth

Το υποπρόγραμμα “Αξιολόγηση” (evaluation) υπολογίζει όλα τα παραπάνω δοσμένο ένα prediction CSV και JSON transcription.

Το ολικό σκορ υπολογίζεται με τον παρακάτω τύπο:

$$S = F_1^a \cdot (1 - FAR)^b \cdot (1 - MR)^c \cdot \left(\frac{1}{1 + |SEG - 1|} \right)^d$$

όπου a, b, c, d είναι τα βάρη της κάθε μετρικής, με την ιδιότητα $a + b + c + d = 1$.

Αναφορά Επιδόσεων Ταξινομητών

Κατ' αρχάς, η εκπαίδευση έγινε με ένα υποσύνολο των αρχείων ομιλίας και θορύβου για λόγους ταχύτητας. Δεν άκουσα ένα-ένα τα αρχεία γιατί πάλι ήταν πολλά, επομένως υπάρχει το ενδεχόμενο τα αρχεία που επέλεξα να μην είναι 100% ποίκιλα. Για την ομιλία έσβησα όλα τα "us-gon" αρχεία και κράτησα ~15 από τα "librivox". Για το θόρυβο, μείωσα σημαντικά τα αρχεία και από τους δύο καταλόγους. Ύστερα από τη συρρίκνωση του συνόλου των αρχείων, ξεκίνησε η εκπαίδευση όπως περιγράφεται στην ενότητα "Κατασκευή Συνόλου Δεδομένων". Αυτό περιλαμβάνει τη λειτουργία του υποπρογράμματος "Εκπαίδευση" (train).

Ύστερα, χρησιμοποίησα το ~2:40 ώρες αρχείο ήχου που είναι πολλά άτομα σε ένα δωμάτιο ως είσοδο για την πρόβλεψη. Το αρχείο περνάει από το pipeline και παράγεται μια ακολουθία από foreground/background τμήματα. Μετά από το τερματισμό του pipeline, παράγεται το CSV αρχείο στην επιθυμητή μορφή. Αυτό είναι μέρος του υποπρογράμματος "Δοκιμή" (test)

Τέλος, πέρασα το JSON transcript (S01.json) στο υποπρόγραμμα "Αξιολόγηση" (evaluate) μαζί με το CSV και παράγεται ένα αρχείο evaluation.json. Το παραχθέν JSON αρχείο περιέχει διάφορα στατιστικά και τις μετρικές αξιολόγησης μαζί με το ολικό σκορ απόδοσης. Με βάση τα δεδομένα του evaluation.json θα μιλήσω για τους δύο ταξινομητές.

MLP

Οι δοκιμές με ταξινομητή το MLP φέραν αρκετά σταθερά αποτελέσματα παρά τις αλλαγές στις υπερπαραμέτρους (hyperparameters). Έγιναν δοκιμές με διάφορα layer sizes (πάντα 2 στρώματα, όπως ζητάει η εκφώνηση) για να βρεθεί η καλύτερη ρύθμιση. Όλα τα παρακάτω δεδομένα έχουν εξαχθεί από δοκιμές με το ταξινομητή εκπαιδευμένα πάνω σε σύνολο εκπαίδευσης (training set) μεγέθους ~1,500,000.

Layers	Score	Recall	Precision	F1	FAR	Segmentation
32, 16	66.4%	79.762%	81.577%	0.806	65.621%	0.996
64, 32	70.7%	64.394%	87.936%	0.743	32.181%	1.322
128, 64	71.7%	64.220%	89.089%	0.746	28.653%	1.319
256, 128	70.0%	63.582%	87.714%	0.737	36.418%	1.355

	Foreground				Background			
Layers	%	Average	Max	Min	%	Average	Max	Min
32, 16	76.7%	3.47s	62.13s	0.41s	23.3%	1.05s	13.15s	0.3s
64, 32	57.4%	1.96s	25.47s	0.41s	42.6%	1.45s	16.9s	0.3s
128, 64	56.5%	1.93s	19.1s	0.41s	43.5%	1.49s	23.6s	0.3s
256, 128	56.9%	1.89s	16.9s	0.41s	43.1%	1.43s	17.2s	0.3s
TRUTH	78.5%	3.54s	63.0s	0.23s	21.5%	0.97s	25.6s	0.01s

Από τα παραπάνω δεδομένα βλέπουμε πως σε μια αρκετά δύσκολη δοκιμή, το σύστημα δίνει πάνω από 70% ολικό σκορ, που δεν είναι καθόλου κακό.

Εδώ αξίζει να σημειωθεί πως οι μετρικές δεν αξιολογούν μόνο τον ταξινομητή, αλλά και το υπόλοιπο pipeline (post-processing). Επομένως, επειδή βλέπουμε ότι η δοκιμή με MLP ρυθμισμένα με στρώματα (32, 16) έχει Segmentation Ratio ≈ 1.0 – ο αριθμός των “foreground” είναι σχεδόν ίσος τόσο στη πρόβλεψη, όσο στο ground-truth, δεν σημαίνει πως ο ταξινομητής μόνος του το έκανε αυτό. Στην πραγματικότητα, χωρίς post-processing, το segmentation ratio θα ήταν πιθανόν πολύ υψηλότερο, λόγω της έλλειψης smoothing σε γειτονίες τμημάτων (segment neighbourhoods).

k-NN

Για την ταξινόμηση με k-nearest neighbours κατάφερα να κάνω μόνο μια δοκιμή λόγω της απαίσιης απόδοσης του ταξινομητή με δεδομένα υψηλών διαστάσεων (42 διαστάσεις είναι πολλές για k-NN). Το training set παρέμεινε ίδιο για τις δοκιμές του MLP και του k-NN. Παρακάτω παρουσιάζεται η αξιολόγηση του ταξινομητή:

k	Score	Recall	Precision	F1	FAR	Segmentation
5	51.11%	29.385%	88.908%	0.442	13.354%	1.249

Παρουσιάζονται επίσης τα στατιστικά των foreground/background τμημάτων:

	Foreground				Background			
k	%	Average	Max	Min	%	Average	Max	Min
5	25.93%	0.935s	14.47s	0.41s	74.07%	2.671s	60.98s	0.3s
T	78.5%	3.54s	63.0s	0.23s	21.5%	0.97s	25.6s	0.01s

Σε γενικές γραμμές, η απόδοση του k-NN είναι πολύ κατώτερη από του MLP με κάθε τρόπο. Προσωπικά πιστεύω πως ταξινομητής k-nearest neighbours δεν ταιριάζει στα πλαίσια τέτοιου πεδίου (εντοπισμός ομιλίας) επειδή:

1. Η δοκιμή με αυτόν παίρνει ~12 ώρες για ~2.5 ώρες εισόδου. Συγκριτικά, ο MLP παίρνει ~30 δευτερόλεπτα.
2. Τα αποτελέσματα, ακόμα και για εισόδους με καθαρή ομιλία χωρίς θόρυβο είναι εξίσου χαμηλής ποιότητας.

Παράρτημα Α – Εγχειρίδιο Χρήσης

Όπως αναφέρθηκε στην εισαγωγή, το σύστημα αποτελείται από τρία υποπρογράμματα. Κάθε υποπρόγραμμα έχει το δικό του σκόπο και χρησιμοποιείται ως μέρος της διαδικασίας Train-Test-Evaluate. Αν επιθυμείτε να δουλέψετε το σύστημα, θα εκτέλεσετε και τα τρία υποπρογράμματα με τη σειρά που παρουσιάζονται. Όλα τα υποπρογράμματα εκτελούνται καλώντας το ίδιο Python script, που βρίσκεται στα αρχεία κώδικα μέσα στο κατάλογο **src** με το όνομα **main.py**. Το script (και τα script από τα οποία εξαρτάται) χρησιμοποιεί τις βιβλιοθήκες **NumPy**, **SciPy**, και **Scikit-Learn**. Για τη διεπαφή χρήστη έχει αναπτυχθεί μια απλή διεπαφή τερματικής γραμμής (Command-Line Interface – CLI). Η εν λόγω διεπαφή χρησιμοποιείται σαν παραδοσιακό CLI πρόγραμμα, για παράδειγμα με το flag *-help* εμφανίζεται κείμενο που επεξηγεί και βοηθάει στην κατανόηση των διάφορων εντολών και παραμέτρων.

```
→ src git:(main) X ./main.py --help
usage: main.py [-h] {train,test,evaluate} ...

Voice Activity Detection (VAD) system using basic machine learning

positional arguments:
  {train,test,evaluate}
    train              Train a classifier on speech and noise data.
    test               Test a trained classifier.
    evaluate           Evaluate test outputs using ground-truth transcripts.

options:
  -h, --help          show this help message and exit
```

Το υποπρόγραμμα **train** αποσκοπεί αφενός στην κατασκευή του training set (βλ. Ενότητα “Κατασκευή Συνόλου Δεδομένων”) και αφετέρου στην εκπαίδευση ενός ταξινομητή.

```
➔ src git:(main) X ./main.py train --help
usage: main.py train [-h] -m {KNN,MLP} -s SPEECH -n NOISE [-l LAYERS [LAYERS ...]]

options:
  -h, --help            show this help message and exit
  -m, --model {KNN,MLP}
                        The classifier to use
  -s, --speech SPEECH   The speech directory containing audio files which will be used to
                        train the classifier
  -n, --noise NOISE     The noise directory containing audio files which will be used to train
                        the classifier
  -l, --layers LAYERS [LAYERS ...]
                        The hidden layer sizes of the MLP classifier.
```

Το υποπρόγραμμα **test** χρησιμοποιεί ένα εκπαιδευμένο ταξινομητή από την εκτέλεση του **train**, εκτελεί ολόκληρο το pipeline (pre-process → post-process), και εξάγει ένα CSV με τις προβλέψεις.

```
➔ src git:(main) X ./main.py test --help
usage: main.py test [-h] -r RESULTS -m {KNN,MLP} -i INPUT [-l LAYERS [LAYERS ...]]

options:
  -h, --help            show this help message and exit
  -r, --results RESULTS
                        The directory where the results (CSV, analytics) will be stored
  -m, --model {KNN,MLP}
                        The classifier to use
  -i, --input INPUT     The test directory (or file) which will be used for testing the classification process
  -l, --layers LAYERS [LAYERS ...]
                        The hidden layer sizes of the MLP classifier.
```

Το υποπρόγραμμα **evaluate** εισάγει ένα CSV προβλέψεων και ένα JSON transcript και υπολογίζει τις μετρικές αξιολόγησης για τα δεδομένα.

```
➔ src git:(main) X ./main.py evaluate --help
usage: main.py evaluate [-h] -t TRANSCRIPT -c CSV -r RESULTS

options:
  -h, --help            show this help message and exit
  -t, --transcript TRANSCRIPT
                        The path to the JSON transcription
  -c, --csv CSV         The path to the predictions in CSV format
  -r, --results RESULTS
                        The path to the results folder where the evaluation will be stored
```


Παράρτημα Β – Οπτικοποίηση Προβλέψεων

Προκειμένου να μπορούμε εμείς (άνθρωποι) να αξιολογήσουμε μια ταξινόμηση, έφτιαξα και μια συμπληρωματική οπτικοακουστική παραθυρική εφαρμογή το οποίο δέχεται ένα CSV προβλέψεων και το αρχείο ήχου που χρησιμοποιήθηκε για τις προβλέψεις.


```
→ src git:(main) × ../visualizer/visualizer.py --help
usage: visualizer.py [-h] -c CSV -a AUDIO

Voice Activity Detection (VAD) visualizer. The program receives two arguments: a CSV file containing the foreground/background segments, and the audio file which was used for the predictions. If the inputs are valid, a window will open with a 'Play' button. Pressing the button will start playing the audio and the screen will turn GREEN at the timestamps when 'foreground' is flagged on the CSV and RED when 'background' is flagged.

options:
-h, --help            show this help message and exit
-c, --csv CSV          The CSV prediction file
-a, --audio AUDIO      The audio file
```



Πατώντας το κουμπί “Play” ξεκινάει η αναπαραγωγή του ήχου και ταυτόχρονα το χρώμα του παραθύρου γίνεται κόκκινό. Όταν υπάρξει χρονική στιγμή που στο CSV υπάρχει τμήμα που είναι foreground, τότε το χρώμα αλλάζει σε πράσινο. Όταν το τμήμα κάποια χρονική στιγμή είναι background, θα αλλάξει το χρώμα σε κόκκινο πάλι.



Αναφορές

- [1] 'Source-filter model', *Wikipedia*. 1 Απρίλιος 2026. Ημερομηνία πρόσβασης: 28 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο:
https://en.wikipedia.org/w/index.php?title=Source%E2%80%93filter_model&oldid=1346514817#cite_note-2
- [2] D. M. W. Powers, 'Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation', *arXiv.org*. Ημερομηνία πρόσβασης: 29 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο:
<https://arxiv.org/abs/2010.16061v1>
- [3] 'F-score', *Wikipedia*. 22 Μάρτιος 2026. Ημερομηνία πρόσβασης: 29 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο:
https://en.wikipedia.org/w/index.php?title=F-score&oldid=1344848713#cite_note-2